

MYZ 307
Ödev - 4
Ata Atas 040230772

1. Şekil(a)'da gri düzey kanal bilgisi verilen (5x5) lik X görüntüsü, Şekil (b)'de H impuls yanıtı verilen (3x3) lük ayırık zamanlı filtre ile filtrelenmektedir.

$$\overleftarrow{\hspace{1.5cm}} \xrightarrow{\hspace{1.5cm}} N$$

23	25	21	22	20
20	50	61	59	23
23	48	58	50	22
25	49	57	48	24
26	23	21	22	25

(a) Gri düzey görüntü

$$\overleftarrow{\hspace{1.5cm}} \xrightarrow{\hspace{1.5cm}} F$$

-1	0	1
-1	0	1
-1	0	1

(b) (3x3) lük filtre.

a) Filtre çıkışındaki Y öznitelik haritasını, 2-Boyutlu konvolüsyon işlemi ile, hesaplayınız (Strip=1 alınız). Konvolüsyon formülünü yazıp notasyonunuzu tanımladıktan sonra işlemleri ayrıntılı yapınız.

Konvolüsyon output boyutu

$$[(N-F)/stride]+1$$
 işleminden

$$\left(\frac{5-3}{1}\right)+1 = 3 \times 3$$
 bulunur.

①
 $[Row_{1,3} \& Col_{1,3}]$ için element by
 element çarpım sonucu

	-1×23	0×25	1×21
Σ	-1×20	0×50	1×61
	-1×23	0×48	1×58

= 74

Aynı işlemler ② $[Row_{2,3} \& Col_{2,4}]$, ③ $[Row_{2,3} \& Col_{3,5}]$, ④ $[Row_{2,4} \& Col_{1,3}]$, ⑤ $[Row_{2,4} \& Col_{2,4}]$, ⑥ $[Row_{2,4} \& Col_{3,5}]$

⑦ $[Row_{3,5} \& Col_{1,3}]$ ⑧ $[Row_{3,5} \& Col_{2,4}]$ ⑨ $[Row_{3,5} \& Col_{3,5}]$ için hesaplırsa

① = 74 ② = $-25 - 50 - 48 + 22 + 59 + 50 = 8$ ③ = -75
 ④ = 108 ⑤ = 10 ⑥ = -107
 ⑦ = 62 ⑧ = 0 ⑨ = -65

①	②	③
④	⑤	⑥
⑦	⑧	⑨

=

74	8	-75
108	10	-107
62	0	-65


↪ Y öznitelik haritası

b) Y öznitelik haritasını RELU katmanından geçirerek T eşiklenmiş öznitelik haritasını hesaplayınız.

74	8	-75
108	10	-107
62	0	-65

Standart Relu fonksiyonu

$$y(x) = \max\{0, x\}$$



$$y(x_{rc}) =$$

$$\begin{aligned} \max\{0, x_{11} = 74\} &= 74 \\ \max\{0, x_{12} = 8\} &= 8 \\ \max\{0, x_{13} = -75\} &= 0 \\ \max\{0, x_{21} = 108\} &= 108 \\ \max\{0, x_{22} = 10\} &= 10 \\ \max\{0, x_{23} = -107\} &= 0 \\ \max\{0, x_{31} = 62\} &= 62 \\ \max\{0, x_{32} = 0\} &= 0 \\ \max\{0, x_{33} = -65\} &= 0 \end{aligned}$$

Sonuç olarak Relu eşiklenmiş öznitelik haritası " T "

$$T =$$

74	8	0
108	10	0
62	0	0

c) T öznitelik haritasına (1x2) lik "max-pooling" işlemi uygulayarak M çıkışı hesaplayınız.

↓ ↓
r c

Stride yine 1 alınarak →

1 ←

74	8	0
108	10	0
62	0	0

$$\begin{aligned} 1: \max\{74, 8\} &= 74 \\ 3: \max\{108, 10\} &= 108 \\ 5: \max\{62, 0\} &= 62 \end{aligned}$$

2 ←

74	8	0
108	10	0
62	0	0

$$\begin{aligned} 2: \max\{8, 0\} &= 8 \\ 4: \max\{10, 0\} &= 10 \\ 6: \max\{0, 0\} &= 0 \end{aligned}$$

$$M =$$

74	8
108	10
62	0

2. Nesne sezme amaçlı bir derin öğrenme ağında tepe katmanında, regresör çıktısında giriş görüntüsünden sezilen bir nesneye ilişkin sınırlayıcı kutu (bounding box-BB) üretilmesinde, aşağıda formülasyonu görülen kayıp fonksiyonu kullanılmaktadır. Bu denklemde görülen $t_i = (t_{i1} \ t_{i2} \ t_{i3} \ t_{i4})$ vektörü derin ağ tarafından tahmin edilen nesne BB koordinatlarını, $t_i^* = (t_{i1} \ t_{i2} \ t_{i3} \ t_{i4})$ ise bu nesneye ilişkin referans (groundtruth) BB koordinatlarını göstermektedir.

$$L_{reg}(t_i, t_i^*) = smooth_{L-1}(t_i - t_i^*)$$


$$= 0.5(t_i - t_i^*)^2 \quad \|t_i - t_i^*\| < 1$$

$$\|t_i - t_i^*\| - 0.5 \quad \|t_i - t_i^*\| \geq 1$$

a) Derin ağ eğitiminde bu kayıp fonksiyonunun kullanılmasının regresör çıkışında nesne yeri ile ilgili olabildiğince iyi BB ler bulunmasını sağlayabileceğini, formülasyondaki notasyonu kullanarak, açıklayınız.

Tahmin edilen koordinat ve ground truth koordinat arasındaki farkın mutlak değerinin 1'den küçük olduğu durumlarda hatanın karesinin alınması şeklinde daha düzgün ve kolay türevlenebilir bir çizgi izlenmesini sağlayarak hata küçüldükçe gradyanın da küçülmesini sağlar ve minimum hataya daha yavaş ve stabil bir şekilde yaklaşılır. Bununla beraber karesel terim $(t_i - t_i^*)^2$ ifadesini parametrik olarak elde tutarken gradyan hesabı yapmanızı sağlar. $0,5(t_i - t_i^*)^2$ ifadesindeki 0,5 çarpanı türev operasyonu esnasında karesel terimden gelen 2 çarpanını elimine ederek gradyan hesabını kolaylaştırır.

$\|t_i - t_i^*\| - 0,5$ ifadesinde büyük hatalar şeklinde lineer bir çizgi:



izleyerek L_{reg} değerini büyük hatalara karşı daha duyarlı kılar. Bunun yanında lineer ifadenin türevi alındığında koordinat değerlerinin parametrik olarak yazılmamasına sebep olur ve gradyan yalnızca artış ve azalış hakkında yön belirtir. Bu durum ağırlık güncelleme işlemini outlier ve yanlış işaretlemelere karşı dayanıklı kılar.

b) Kayıp fonksiyonunun koordinat değişkenine göre birinci türevini alınız.

$$e = t_i - t_i^* ; \frac{\partial L_{reg}}{\partial t_i} = \frac{\partial L_{reg}}{\partial e} \cdot \frac{\partial e}{\partial t_i}$$

$$L_{reg} = \begin{cases} 0,5 (t_i - t_i^*)^2 & \|t_i - t_i^*\| < 1 \quad (1) \\ \|t_i - t_i^*\| - 0,5 & \|t_i - t_i^*\| \geq 1 \quad (2) \end{cases}$$

$$(1) \rightarrow \frac{\partial 0,5 e^2}{\partial e} = e = t_i - t_i^* \text{ \& } \frac{\partial e}{\partial t_i} = \frac{\partial (t_i - t_i^*)}{\partial t_i} = 1 \text{ yani } \frac{\partial L_{reg}}{\partial t_i} = e \cdot 1$$

$$\text{ve } \frac{\partial L_{reg}}{\partial t_i} = (t_i - t_i^*)$$

$$(2) \rightarrow \frac{\partial (\|e\| - 0,5)}{\partial e} = \frac{\partial \|e\|}{\partial e} = \text{sign}(e) \text{ \& } \frac{\partial e}{\partial t_i} = 1 \text{ yani } \frac{\partial L_{reg}}{\partial t_i} = \text{sign}(t_i - t_i^*)$$

$$\frac{\partial L_{reg}}{\partial t_i} = \begin{cases} (t_i - t_i^*) & \|t_i - t_i^*\| < 1 \\ \text{sign}(t_i - t_i^*) & \|t_i - t_i^*\| \geq 1 \end{cases}$$

3. Aşağıdaki soruları görüşünüzü en fazla 3 madde ile özetleyerek yanıtlayınız. ChatGPT ve benzeri araçların verdiği uzun açıklamaları koymayınız!!!

a) Uzun-kısa-erimli bellekli (LSTM-long-short time memory) ağlar ile Transformatör (transformer) kullanan ağlar arasındaki ORTAK noktalar nelerdir?

1- İkisi de birbirine bağımlı inputlar içeren ve long term memory gerektiren problemler için öğrenmeyi amaçlar

2- Geri yayılım (Backpropagation) ve gradyan hesabı yaparak end to end öğrenme yaparlar.

3- Zamana bağlı öğrenim yapımları sayesinde dil modeli gibi modellerde aynı kelimeyi farklı bağlamlarda değerlendirebilme mümkün kılınır.

b) LSTM kullanan ağlar ile Transformatör kullanan ağlar arasındaki FARKLI noktalar nelerdir?

1- LSTM'ler seri hesaplama yapar (t. adım için t-1 de gereklidir).
Transformer'lar tüm tokenleri aynı anda işleyerek paralel hesaplama yapar.

2- LSTM uzak geçmişteki veriyi "gate"lerde geçirerek taşır ve bu yüzden uzun dizilerde bilgi kayıtlayabilir. Transformerlar tokenler arasında "attention" kurarak uzak geçmişteki token ile en son token arasında doğrudan bağlantı kurar.

3- LSTM: Zaman içinde seri şeklinde ilerleme olur, n boyutlu veri için $O(n)$ hesap maliyeti.
Transformer: Attention matrisi her tokeni diğer tüm tokenlerle ilişkilendirir ve $O(n^2)$ hesap maliyeti çıkar.

c) Transformatör mimarisinin LSTM mimarisine göre en temel üstünlüğü ve en temel dezavantajı nedir?

Self-Attention mekanizması uzun verideki bütün tokenleri birbirleriyle ilişkilendirerek uzun veri dizilerinde eski verilere yönelik daha iyi performans gösterir.

Fakat dizi uzunluğu arttıkça zaman karmaşıklığı $O(n^2)$ şeklinde arttığı için yüksek hesap maliyetine sahiptir. LSTM long term hafıza performansının etkilenmeyeceği uzunluktaki veride benzer performans, LSTM'den daha yüksek maliyetle elde edebilir.

d) ChatGPT uygulamasında kullanılan derin öğrenme mimarisi nedir?

GPT → generative pretrained transformer, transformer'ın sadece decoder kısmını kullanarak önceki tokenleri kullanarak metin üretmeyi amaçlayan bir mimari kullanır.

e) Transformatör ve LSTM mimarileri ile CNN mimarileri arasında FARKLILIK var mıdır? Nasıl?

Farklılık vardır. LSTM ve Transformer RNN'lerin özelleştirilip geliştirilmiş halleridir. Sıralı veriyi sırasını göz önünde bulundurarak bağlarına göre işleneyi ve öğrenmeyi amaçlarlar.

CNN ise fotoğraf pikselleri gibi uzamsal verileri işlemek, piksel komşularına bakarak kenar, köşe gibi desenleri tespit etmek için yerel komşuluklar arasında ilişki kurar ve paralel hesaplama yapan bir mimaridir.